

KONTAKT

Hof, Bayern, Deutschland

harshvirani.91@gmail.com

+49 15510862272

linkedin.com/in/harshvirani914

github.com/HarshVirani914

harsh-virani.vercel.app

STUDIUM

M.Sc. AI and Robotics
Hochschule Hof, Bayern
März 2025 – März 2027 (voraussichtlich) · GPA 1.8

Generative KI, Machine Learning, Deep Learning, Data Mining, Fortgeschrittene KI-Anwendungen, Predictive Maintenance & Zustandsüberwachung, Intelligente Robotik, Forschungsmethodik & wissenschaftliches Schreiben.

B.Sc. Informatik
Veer Narmad South Gujarat University
August 2021 – März 2024 · GPA 9.01

Datenstrukturen & Algorithmen, Objektorientierte Programmierung, Software Engineering, Datenbanksysteme, Web- & Mobile-Entwicklung, Mathematik (Analysis, Statistik, Lineare Algebra).

KERNKOMPETENZEN

LangGraph · LangChain · RAG · Multi-Agent Systems · Prompt Engineering · LLM-Evaluation · Python · FastAPI · Pydantic · Celery · Redis · REST APIs · React · Next.js · TypeScript · shadcn/ui

SPRACHEN

Englisch — fließend

Deutsch — B2

Hindi, Gujarati — Muttersprache

ZERTIFIKATE

Oracle Agentic AI Certified Foundations Associate
Oracle · August 2026

Introduction to Model Context Protocol
Anthropic · March 2026

AUSZEICHNUNGEN

Dean's List
Hof University of Applied Sciences · 2025
Top academic performer

ML Hackathon 2.0 — 2nd Place
2023

Harsh Virani

KI-Engineer · Agentische Systeme, RAG & LLM-Evaluation

PROFIL

Softwareentwickler mit Fokus auf angewandte KI: produktive LangGraph-Agenten-Pipelines, Retrieval-Augmented Generation und LLM-Evaluation. Ein Jahr im Ausliefern von Full-Stack-Produkten, jetzt spezialisiert auf fehlerisolierte Multi-Agenten-Systeme mit Kosten-, Latenz- und Groundedness-Instrumentierung. M.Sc.-Student KI & Robotik in Deutschland, verfügbar als Werkstudent.

BERUFSERFAHRUNG

Software Engineer, AI & Full-Stack

Juli 2024 – März 2025

TechStaunch Solutions PVT LTD

- Enterprise-GenAI-Systeme (RAG-Pipelines, Chatbots, agentische Workflows) mit **LangChain, LlamaIndex und FastAPI** gebaut und die Retrieval-Effizienz um **35 %** verbessert.
- On-Premise-LLM-Anpassung und RAG-Pipelines geliefert, die **ohne externe API-Aufrufe** laufen und Enterprise-Vorgaben zu Datenschutz und Datenresidenz erfüllen.
- KI bedarfsgerecht in laufende Kundenprodukte integriert: einen **Video-Snapshot-Generator** mit automatischer Transkript-Extraktion und eine **automatisierte Lead-Generierungs-Pipeline** für den eigenen Funnel des Unternehmens — jeweils als Ersatz für einen manuellen Ablauf.
- Full-Stack-Features für eine produktive E-Commerce-Plattform (**10.000+ tägliche Nutzer**, **50.000+ Transaktionen/Tag**) umgesetzt und die Deployment-Zeit um **87 %** reduziert (8 h auf 50 min) mit einer AWS-CI/CD-Pipeline.

MASTERARBEIT

Deep Research LLM-Agents for Office Work — An Empirical Investigation with Spreadsheet Software

M.Sc.-Arbeit · Hochschule Hof · Betreuer: Prof. Dr. René Peinl · in Bearbeitung

- Agenten-Harness für Tabellenarbeit gebaut: ein fester Satz von Aktionen (Formel schreiben, filtern, sortieren, Pivot, Zellbereich lesen, validieren), die jeweils strukturiertes Feedback zurückgeben, mit dem sich das Modell über mehrere Turns selbst korrigiert.
- Die Ausführungsumgebung als zwei Container auf Kubernetes entworfen, einen für das LLM und einen mit LibreOffice über dessen Python-UNO-Bridge, pro Task netzisoliert, sodass der Nutzer lokal nichts installiert.
- Große Tabellen aus dem Kontextfenster des Modells herausgehalten (wenige tausend Zeilen überschreiten bereits 128k Tokens), indem Queries, Filter und Aggregationen in der Tabellen-Engine laufen und nur die Ergebnisse zurückgehen.
- Zwei kontrollierte Experimente auf SpreadsheetBench entworfen: zuerst ein Vergleich von rund fünf open-weight, selbst-hostbaren Modellen auf einem festen Harness, dann ein Test dieses Harness gegen SWE-agent, Claude Code und Cline auf dem stärksten Modell, um den Anteil des Modells an der Agentenleistung vom Anteil des Harness zu trennen (Pass-Rate, Zell- und Task-Genauigkeit, Effective-Step-Ratio, Kosten, Laufzeit).

AUSGEWÄHLTE PROJEKTE

Zolldeklaration ohne Handarbeit (Tdec)

Produktive 11-Knoten-LangGraph-Pipeline mit Browser-Control- und Tool-Calling-Agenten

- **11-Knoten-LangGraph-Pipeline** (Extraktion bis Erzeugung der staatlichen XML) mit einem Guard-Decorator pro Knoten entworfen, der ein fehlerhaftes PDF zu einem markierten Job statt zu einem abgestürzten Worker macht — verwandelt eine **30-40-minütige** manuelle Deklaration in einen **~30-60-Sekunden**-Lauf.
- **LLM-gesteuerten Headless-Browser-Agenten** (browser-use + Gemini + Playwright) ergänzt, der bot-geschützte FedEx-/UPS-/DHL-Portale automatisch ausliest, plus eine konfidenzgesteuerte multimodale Extraktionsstufe, die nur unsichere Felder markiert — reduziert die Prüfung auf wenige Kontrollen statt des ganzen 37-46-Felder-Formulars.

MYSY Scholarship
Government of Gujarat · 2021–2024
Outstanding academic progress

TOOLS & PLATTFORMEN

PyTorch · Hugging Face · XGBoost · scikit-learn · TensorFlow · Docker · CI/CD · AWS · GCP · Vercel · PostgreSQL · Qdrant · FAISS · Langfuse · LangSmith · Sentry · pytest

VERFÜGBARKEIT

Ab sofort verfügbar

15-20 Std./Woche (Semester), 30-40 Std./Woche (vorlesungsfrei)

Langfristig über das gesamte Masterstudium

AKTUELLER FOKUS

Multi-Agenten-Orchestrierung und Fehlerisolierung

LLM-Evaluation: Frameworks und Referenz-Benchmarks

Retrieval-Augmented Generation: hybride Suche und Reranking

Observability für Kosten, Latenz und Groundedness

- Golden-Set-Evaluationsharness gebaut, das die echte Pipeline mit deterministischer + LLM-Judge-Bewertung durchläuft und die Feldgenauigkeit über Prompt- und Pipeline-Iterationen von **45,8 % auf ~88 %** (F1 0,92) hob.

Technologien: FastAPI, LangGraph, Celery, Redis, Gemini, browser-use, Next.js

RAG-Support-Agent ohne Halluzination

6-Knoten-LangGraph-Graph, RAGAS-Benchmark bei 0,958 Faithfulness

- **6-Knoten-LangGraph-Agenten** (klassifizieren bis routen bis abrufen bis generieren bis bewerten bis wiederholen) entworfen, dessen Reflexionsschleife bei nicht belegten Antworten die eigene Suchanfrage umschreibt und neu abruft — fing und überarbeitete Antworten in **5 von 24** Evaluationsfällen, statt sie auszuliefern.
- Hybrides Dense+Sparse-Retrieval mit RRF-Fusion und Cross-Encoder-Reranking über ~20 vorab geholte Kandidaten gebaut; hob RAGAS auf **0,958 Faithfulness / 0,889 Context Precision** auf einem 24-Fälle-Set, auf dem reines Dense-Retrieval exakte Begriffe verfehlte.
- Den torch-/sentence-transformers-Dienst auf einen Free-Tier-Host gebracht: CPU-only-PyTorch-Wheel und ins Image gebackene Reranker-Modelle senkten die Deploy-Größe um **~90 %** (~2,5 GB auf ~200 MB) und beseitigten Hugging-Face-429-Fehler beim Kaltstart, sodass der Container sofort healthy wird.

Technologien: FastAPI, LangGraph, Qdrant, Neon Postgres, RAGAS, Render, Next.js

Regressions-Radar für LLM-Agenten

Trajektorien-basierte Evaluation und Regressionserkennung für LLM-Agenten

- Eine kanonische **Agent-IR** über OpenTelemetry-GenAI-Spans (LangGraph-Instrumentor bis ClickHouse) entworfen, die Multi-Turn-Sessions und die Tool-/Modell-Schritte jedes Turns rekonstruiert — reduziert die Multi-Turn-Erfassung von N Traces plus Cross-Trace-Gruppierung auf **einen Trace pro Konversation** und die Framework-Anbindung auf einen einzigen Adapter.
- **9 deterministische Evaluatoren** (Tool-Wahl, Tool-Argumente, JSON-Schema, Task-Success, Latenz, Kosten, Trajektorien-Effizienz, Tool-Reihenfolge) auf einem `evaluate(case, trajectory)`-Vertrag ausgeliefert, sodass objektive Prüfungen **keinen LLM-Judge** brauchen und bei null API-Kosten reproduzierbar bleiben.
- Unsicherheits-bewusste Aggregation gebaut (Wilson-Intervalle für Pass-Raten, Bootstrap-CIs für kontinuierliche Metriken), die eine Änderung zwischen zwei Versionen nur dann als Regression markiert, wenn sie statistisch belastbar **und** praktisch bedeutsam ist — beseitigt Fehlalarme aus reinem Delta-Vergleich.

Technologien: LangGraph, OpenTelemetry, ClickHouse, FastAPI, Pydantic v2, PostgreSQL, Next.js

FORSCHUNG

- Überblick über das LLM-Ökosystem: Decoder-only-, Encoder-only- und Encoder-Decoder-Architekturen für NLU/NLG, inkl. Prompt-Strategien, Halluzinations-Minderung und Code-LLMs.
- Literaturüberblick zu KI-gestützten Low-Code-/No-Code-Plattformen: LLM-Agenten als Brücke zwischen Ingenieuren und Citizen Developers, Task-Technology-Fit und Workflow-Integration.